01 Escopo e dados disponíveis

Pergunta: como delimitar **polígonos candidatos a cafezais existentes** em imagens multiespectrais, sem confundir detecção com aptidão agrícola ou confirmação em campo? O processamento usa os pixels do GeoTIFF recebido; não consulta resultados pré-computados.

Imagem original 16/08/2025 · Sentinel-2 L2A	**Área e grade** Guaxupé/MG · 512×512 · 10 m · EPSG:32723
Entradas B02, B03, B04, B08 · máscara SCL 20 m	**Outras datas processadas** 21/07/2025 e 25/10/2025 · IDs STAC

02 Fluxo executado em Python



Pré-processamento: reflectância = DN × 0,0001 − 0,1 (metadados do kit; transformação feita uma vez); exclusão de NoData pelas máscaras GDAL. SCL reamostrada por vizinho mais próximo para mascarar nuvens/sombras; NDVI, GNDVI, EVI2 e texturas locais. **Saída:** coerência 3×3, regiões ≥0,2 ha, GeoJSON WGS84 e área geodésica.

Treinamento: MapBiomas Coleção 11/2025 (classe 46 = café) como **supervisão fraca**. A revisão introduziu classes café/floresta/pastagem/mosaico/outros, erosão de 1 célula no rótulo nativo de 30 m, amostragem de 1 ponto por célula e três datas; avaliação com blocos espaciais e teste temporal.

03 Alternativas e decisão técnica

Abordagem	Situação	Motivo e decisão
Índices + limiares	Testada	Baixo custo, mas confunde vegetação densa com café. Não adotada como classificador final.
Random Forest multiclasse	Implementada	Compatível com quatro bandas, roda em CPU e permite investigar erros e reproduzir o processamento.
Prithvi-EO-2.0 / Clay	Pesquisadas, **não testadas**	Modelos fundacionais promissores, mas requerem adaptação dos dados, classificação específica de café e validação adicional; ganho não demonstrado no prazo.

Prithvi-EO-2.0 usa originalmente seis bandas HLS, diferentes das quatro do kit; o **Clay** oferece representações para dados Sentinel-2. Bandas red-edge/SWIR também foram consideradas para trabalhos futuros, sem experimentos nesta entrega. Fontes: NASA/IBM e Clay.

04 Fundamentação - três fontes primárias

1 · Parreiras et al. (2025). Dense Time Series of Harmonized Landsat Sentinel-2 and Ensemble Machine Learning to Map Coffee Production Stages. Remote Sensing 17(18):3168. Séries temporais e RF/XGBoost. doi:10.3390/rs17183168

2 · Alves, Volpato & Campos (2021). Mapeamento automatizado de áreas de café em Minas Gerais. Embrapa Café. Sentinel-2 e classificação orientada a objetos. Embrapa, doc. 1134278

3 · Schneider, Alves & Ferreira (2025). Coffee crop detection and mapping using Sentinel-2 data and spatial coherence. TAAE 9(3). Coerência espacial em classificação. doi:10.31422/taae.v9i3.64

Dados auxiliares: Sentinel-2 L2A / SCL (Copernicus); MapBiomas Brasil Coleção 11 / 2025, 30 m (MapBiomas). Referência temática **não é verdade de campo**.

05 Resultados obtidos - comparação com MapBiomas

Áreas em hectares dos polígonos candidatos e suas **sobreposições aproximadas** com as classes do mapa anual de 2025. Não representam acurácia real nem hectares de café confirmados.

Cena	Classificador	Candidatos	Sobrep. café	Sobrep. floresta
Ago/2025	RF anterior	96,02 ha	29,07 ha	7,07 ha
Ago/2025	RF revisado · 0,50	22,66 ha	12,14 ha	1,03 ha
Out/2025	RF anterior	83,27 ha	6,30 ha	66,45 ha
Out/2025	RF revisado · 0,50	10,96 ha	7,94 ha	0,00 ha

Interpretação: a revisão reduziu fortemente candidatos sobre floresta, sobretudo em outubro (66,45 → 0,00 ha), **mas também reduziu a cobertura de café rotulado em agosto** (29,07 → 12,14 ha). Não há evidência para declarar superioridade geral do modelo.

06 Validação e erros efetivamente encontrados

- **Validação por blocos espaciais:** F1 ≈ 0,355 para o RF revisado, contra rótulos indiretos; **teste leave-one-date-out:** F1 ≈ 0,391 retendo outubro no ensaio temporal. Protocolos distintos; F1 dos modelos antigos e novos não é comparável diretamente.
- **Falha de classificação:** o RF binário treinado em julho/agosto confundiu floresta com café na cena de outubro; foram introduzidos negativos difíceis, rótulos menos ruidosos e treinamento multidata. Sem ablação completa, não atribuímos o ganho a um fator isolado.
- **Falha de software:** operações **Affine @ tuple** quebravam a sobreposição com a biblioteca instalada. Corrigidas para **Affine * tuple**, com testes de regressão.

Cuidado metodológico: outubro foi usado na seleção da abordagem e no treinamento da versão final; **não é um conjunto final independente/intocado**.

07 Limitações que afetam a interpretação

- **Rótulos e escala:** MapBiomas é anual e tem resolução aproximada de 30 m; reamostrar para 10 m não adiciona detalhe real. Sem inventário de campo ou teste em região diferente, não é possível declarar precisão da identificação de café.
- **Generalização:** banda visível + NIR, sazonalidade, práticas de manejo, poda, sombreamento, nuvens e pixels mistos podem confundir cafezais, floresta e outras culturas.
- **Saída operacional:** scores RF não calibrados; corte de score e área mínima de 0,2 ha podem omitir talhões. Polígonos representam **candidatos para revisão**, não propriedades validadas.

08 Reprodutibilidade, direitos de uso e IA

Arquivos gerados por upload: candidatos.geojson (EPSG:4326; áreas individuais), **imagem_classificada.png**, **imagem_mapa.png**, **classificacao.tif** e **resultado.json**. Hectares vêm das geometrias vetorizadas e do cálculo geodésico.

Proveniência e licenças: URLs/IDs STAC em **sample/**, **additional/**, **unseen/** e **reference/**. Crédito: “Contains modified Copernicus Sentinel data (2025)”. MapBiomas Coleção 11: CC BY 4.0, conferida em 29/10/2026; atribuir, vincular a licença e indicar recorte/reamostragem. Bibliotecas Python abertas declaradas em **pyproject.toml**.

Uso de IA: ChatGPT/GPT-6 e Deep Research apoiaram pesquisa, programação e documentação; nenhum substituiu a análise dos pixels, gerou rótulos ou estimou hectares. O chat generativo depende de credencial no servidor; sem ela, a aplicação informa a contingência determinística.